

中国企业的人工智能投入： 来自招聘大数据的发现

方 颖 王翔宇 叶梦芊 赵西亮

摘 要:本文构建了涵盖近 10 万项技能维度的中国劳动力技能大词典,并将其与大规模企业招聘数据进行匹配,从人力资本视角量化测度我国企业的人工智能投入强度。经三种方法交叉验证,该指标能够有效识别企业间人工智能发展水平的差异。在此基础上,本文系统对比了基于年报等公开文本信息挖掘的人工智能测度指标与基于人力资本投入的测度指标,研究发现,二者分别捕捉了企业人工智能发展的不同维度,基于公开披露文本的测度更多反映企业在人工智能领域的前瞻性布局与技术定位。最后,本文以人工智能技术进步作为外生冲击开展资产定价分析,结果表明,投资者在评估企业人工智能水平时,更容易受到公开披露信息的影响;相比之下,对企业实际投入信息的分析,更多建立在企业已进行相关披露的基础之上。本文研究对更好地测算我国企业人工智能投入提供了参考。

关键词:人工智能投入;招聘数据;大数据分析

JEL 分类号:J24, O33, G14 **文献标识码:**A **文章编号:**1002-7246(2026)05-0152-18

一、引 言

人工智能是新一轮科技革命和产业变革的重要驱动力量,将对全球经济社会发展和

收稿日期:2025-10-24

作者简介:方 颖,经济学博士,教授,厦门大学王亚南经济研究院、厦门大学大数据金融交叉实验室,
E-mail:yifst1@xmu.edu.cn.

王翔宇,博士研究生,厦门大学邹至庄经济研究院,E-mail:wangxiangyu@stu.xmu.edu.cn.

叶梦芊(通讯作者),经济学博士,助理研究员,福建省科学技术信息研究所,E-mail:em_ymq08@163.com.

赵西亮,经济学博士,教授,厦门大学经济学院、王亚南经济研究院,E-mail:zhaoxl2.03@xmu.edu.cn.

* 本文感谢国家自然科学基金重大项目《人工智能时代劳动力市场理论与微观结构计量研究》(72595870)、国家自然科学基金重大项目课题二《人工智能时代人力资本供给的测度与建模》(72595875)和国家社会科学基金一般项目“人工智能技术应用对劳动力行业间配置和工资的影响研究”(23BJL042)的资助。感谢匿名审稿人的宝贵意见,文责自负。

人类文明进步产生深远影响¹。随着人工智能技术不断进步,越来越多的企业在人工智能方面进行投入,以实现生产效率的提升和生产方式的转型升级。然而,人工智能技术无法通过财务报表等渠道直接观测。如何有效测算企业层面人工智能投入强度成为人工智能相关研究的重要基础。

人工智能是典型的智力密集型技术,掌握算法创新、数据处理以及对应用场景深度理解的人才 是人工智能投入的核心,而计算设备和存储系统等硬件要素则是围绕人才搭建的辅助设备(何晓斌和石一琦,2019; Brynjolfsson et al., 2021)。基于此,我们提出了一种基于企业招聘大数据的测算方法,其核心在于以企业人工智能岗位招聘占总招聘的比例作为投入强度的代理指标,而岗位属性则通过招聘文本中的技能要求来界定。

为验证基于招聘大数据测算方法的合理性,本文首先使用现有文献中常用的“榜单法”和“专利法”进行可靠性检验。但榜单法和专利法的适用样本受限于少数头部企业或一部分高技术企业,为此我们提出了依托资产定价的验证方法。人工智能技术的进步将放大企业已有人工智能投入的回报²,并在资本市场转化为股价收益率的差异。将 ChatGPT 的发布作为人工智能技术的外生冲击,发现人工智能高投入的企业组合在 ChatGPT 发布窗口期内的超额收益率显著高于低投入企业组合,且人工智能投入和企业累计异常收益显著正相关。这表明本文的测度和投资者对企业人工智能投入水平的认知高度吻合,且独立于其他公司特征因素。

已有文献多基于企业年报等已披露的文本信息挖掘,构建数字化或人工智能水平的测度,本文简称为“基于披露的测度”。我们进一步将利用招聘大数据的“基于投入的测度”和利用文本大数据的“基于披露的测度”进行对比分析,研究企业人工智能不同测度方法的信息含量。对比分析发现,两种不同测度之间仅显示微弱的正相关关系,意味着存在较多投入与披露不一致(“言行不一”)的样本。进一步分析显示,尽管“言行不一”样本可能未有效开展人工智能投入,但这并不必然意味着刻意粉饰,还可能源于两类正常原因:其一,披露包含前瞻性内容,存在时间错配;其二,披露受到企业技术位置的影响,反映的不仅是企业自身投入,还可能反映业务关联性或行业整体影响。总体而言,尽管基于披露的测度与当期投入未必完全一致,但依然提供了理解企业人工智能相关情况的有价值信息。

企业的人工智能披露和投入信息会共同塑造投资者对于企业价值的判断,最终表现为金融市场价格波动。因此,本文最后考察了投资者如何综合处理人工智能披露和投入这两类信息,以厘清实体经济人工智能使用影响中国金融市场的具体信息路径。研究发现有以下三点。其一,无论投入高低,“披露溢价”(高披露相对低披露)始终显著,表明部分投资者主要依据披露评估企业的人工智能水平;其二,“投入溢价”(高投入相对低投入)在高披露企业中稳健存在、在低披露企业中虽存在但不稳健,且前者溢价幅度更大,

1 详见 https://www.gov.cn/yaowen/liebiao/202406/content_6958352.htm。
2 Rock (2022) 的研究发现,深度学习框架 TensorFlow 的发布,使得前期进行了 AI 技能招聘的企业价值显著提升。具体而言,企业积累的 AI 技能每提升 1 个百分点,其市值得益于 TensorFlow 发布的程度高达 1100 万美元。

表明投资者在处理两类信息时存在优先级差异,在企业披露程度较高的前提下,投资者愿意给予高投入企业更高估值;其三,“披露溢价”在短期即显现,而“投入溢价”则在更长期限内才逐步显现,说明投资者对披露信息的吸收更快、对投入信息的获取与理解存在时滞。总体而言,投资者较难收集和解读企业在人工智能方面的投入信息,年报披露信息仍是投资者倚仗的最关键信息源。

本研究边际贡献有以下几个方面。第一,提出了一种基于招聘大数据的方法来量化我国企业的人工智能投入状况。该方法不依赖企业主动披露的信息,因而同时适用于评估上市公司与非上市公司,且能够有效规避企业不实宣传行为的干扰。一系列检验结果证实了其可靠性。此外,仅需调整技能匹配的关键词,该方法即可扩展至其他技术领域的投入测算,具备广泛适用性,在已有文献的基础上(邵红霞和方军雄,2006;张俊芳等,2018;陶锋等,2023;许宪春等,2025;方颖等,2025)进一步丰富了测度我国无形资产投入这一难题的可用工具箱。第二,采用“披露—投入”对照分析方法,系统考察了我国企业人工智能信息披露的可靠性,并全面展示了人工智能披露所承载的信息内容。披露信息在研究我国企业数字技术使用情况中占据重要地位(吴非等,2021;肖土盛等,2022;姚加权等,2024),本研究结果有助于更好地认识企业数字技术使用的经济后果。第三,通过考察外生技术冲击窗口内的资产表现,展示了我国投资者理解企业技术投入时的信息偏好。技术冲击是影响资产价格波动的重要因素(Pástor and Veronesi,2006),投资者如何解读技术冲击对企业价值的影响,构成技术冲击转化为价格现象的关键机制,也是现有文献大量关注的议题(Pástor and Veronesi,2006;Sharma and Narayan,2022;Chu et al.,2025)。既有研究已证实我国企业数字技术使用会影响股价表现(吴非等,2021;马慧和陈胜蓝,2022),但尚未明确投资者如何分析企业技术使用情况,以及不同信息来源的相对优势。本文通过考察外生技术冲击窗口内的资产表现,揭示我国投资者理解企业技术投入的信息偏好,为上述问题提供初步证据,有助于厘清技术冲击从实体经济向金融市场传导的微观机制。

二、测度方法和数据

(一)现有方法述评

现有间接测度我国企业数字化或人工智能技术的方法主要有三类。第一类是文本法,通过统计公司披露文件中“人工智能”相关词汇的出现频率来评估其人工智能技术水平(吴非等,2021;赵宸宇等,2021;方明月等,2022;姚加权等,2024)。然而,对人工智能进行宣传并不需要付出具体的成本,因此宣传强度与投入强度之间可能存在差异。第二类是设备投入法,将人工智能这一无形技术有形化为信息技术相关设备进行测算(刘飞和田高良,2019;祁怀锦等,2020;Müller et al.,2018)。然而,目前尚无人工智能专用设备的标准清单,而相当多设备可以同时用于传统的信息技术和人工智能技术(如计算机、数据存储系统等),难以清晰区分。此外,这两类方法均存在一个缺陷:测算依赖于企业的

自愿披露,因此仅适用于具有披露动机的部分上市公司,容易受样本缺失和选择偏差的影响。第三类是专利法,通过企业人工智能相关专利的申请或授权数量来衡量其技术水平(李哲等,2024;Jiang et al.,2025)。然而,专利是人工智能投入的潜在产出,而非投入的直接要素。企业是否具备意愿和能力将已有技术转化为创新成果,受公司属性和行业特征的制约,人工智能投入并不必然转化为专利产出(金星晔等,2024)。因此,仅比较专利数量难以准确反映人工智能投入强度的差异。

与现有方法不同,本文从人力资本投入角度刻画企业人工智能投入,原因主要有以下三点:第一,人力资本是人工智能开发、部署与应用中的核心要素,相关技能人才的获取本身就是企业开展人工智能投入的基础环节;第二,人工智能投入贯穿数据建设、流程改造到智能决策支持等多个阶段,不同环节对应不同类型的人才需求,因此招聘结构能够更细致地反映企业投入的功能分布与技术层次;第三,相较于年报文本、财务报表和公司公告,招聘数据更直接反映企业在特定时间和技术方向上的真实需求,信息密度更高,也更不易受到披露策略干扰。

(二) 测度方法

为系统刻画企业人工智能投入,本文构建了一套多层次测度框架。现有文献指出,技能要求是岗位的核心特征(Acemoglu and Autor,2011;Autor et al.,2024)。Darendeli et al.(2022)曾利用招聘广告中环境保护相关技能的占比,测算企业在绿色转型中的人力资本投入强度。基于此,整个测度模型从技能出发,核心是使用岗位技能需求的人工智能相关性来判断一个岗位是否属于人工智能岗位。然后按照技能—岗位—公司的层次结构层层向上汇总,最终得到公司一年度层面的人工智能投入强度量化指标。

首先,在招聘文本层,通过构建技能词典对原始招聘文本进行技能抽取,获得岗位需求中的技能集合;其次,在技能层,基于人工智能核心技能并结合技能共现结构,计算各项技能的人工智能相关度;再次,在岗位层,根据岗位所包含技能的人工智能相关度并结合识别阈值,判定岗位的人工智能属性并构建岗位层面的人工智能相关度指标;最后,在企业层,将岗位层指标在企业一年份维度上进行聚合,计算企业人工智能岗位在总岗位需求中的占比,从而刻画企业的人工智能投入强度。

目前尚缺乏可直接用于招聘语料分析的中文职业技能词典,且官方职业分类文件中的工作内容表述与企业招聘文本在用词和颗粒度上存在明显差异。为此,本文以Lightcast、O*NET和ESCO三套国际通行的英文技能数据库为基础,经清洗、标准化与去重后构建初步词典。考虑到英文词典难以充分覆盖中文招聘语境中的本土化技能词汇、行业惯用表述、缩写别称和同义变体,我们进一步基于该初步词典训练了一个基于BERT的命名实体识别工具,对中文招聘文本进行直接技能抽取,以补充我国劳动力市场特有的技能表达(如PPT、PS等)。最终,得到包含99463项技能的中国劳动力技能大词典,并基于该词典从招聘语料中提取出技能需求。词典构建的具体流程细节请参考附录一。

参考Babina et al.(2024),我们采用技能共现的方法,测度每一个被提取技能的人工智能相关度。一个技能如果和四个人工智能核心技能[人工智能(AI)、机器学习(ML)、

图像识别 (IR)、自然语言处理 (NLP)] 出现的频率越高,同时在其他场景下出现的频率越低,就认为该技能是专属于人工智能技术的技能。由此定义任意一个技能 s 的人工智能关联度 (ω_s^{AI}):

$$\omega_s^{AI} = \frac{\text{技能 } s \text{ 与核心技能 (AI、ML、IR、NLP) 共现的次数}}{\text{全部招聘广告中技能 } s \text{ 出现的次数}}$$

这一定义技能与人工智能关联度的方法,具有两大优势。首先,通过分母端的设计,可以有效区分常规信息技术与人工智能专用技术,避免混淆。其次,除四个核心技能外,其他技能的关联度计算完全基于数据驱动,能够客观反映人工智能技术逐年演变的趋势,从而有效避免了“固定清单”式方法与人工智能技术快速发展不匹配的问题。附录附表 2 分别展示了 2015 年和 2022 年的高人工智能相关度技能,从中可以观察到人工智能技术在样本期内的发展和演变趋势。

在岗位层面,我们将一个招聘岗位(对应的职位描述) j 的 AI 关联性指标 ω_j^{AI} 定义为该招聘广告 j 所需的所有技能的人工智能关联性指标 ω_s^{AI} 的平均值,反映了某一岗位的整体人工智能相关性。通过详细对比不同人工智能相关度对应的岗位特征,设定一个阈值 0.05,将 $\omega_j^{AI} > 0.05$ 的岗位定义为人工智能相关岗位,反之则不是¹。

在公司层面,我们计算了公司当年所有招聘岗位中人工智能相关岗位的占比,最终构建出本研究所提出的人工智能投入指标 AIRatio。

(三) 数据来源

本研究涉及数据中,招聘数据来自智联招聘平台(由中国开放数据平台 CnOpendata 收集、整理并将雇主信息标准化后逐年匹配至上市公司);公司年报文本爬取自巨潮信息网;公司专利数据来自国家知识产权局;公司层面的财务变量以及股票价格数据均来源于国泰安(CSMAR)数据库。

三、验证方法

由于招聘平台覆盖面的客观限制、数据处理与测算过程中可能存在的测量误差,以及企业个别异常招聘行为的干扰,本文构造的 AIRatio 指标在部分企业间不可避免地可能偏离其真实的人工智能投入水平。为此,我们设计并实施了一套较为完整的指标可靠性检验流程,旨在确认这些潜在偏误不会系统性地扭曲企业间人工智能投入强度的相对排序与横向比较结果。

下面将详细阐述如何使用评级验证法、专利验证法和资本市场验证法对本测度的可靠性进行检验,并汇报相关检验结果。其中前两个方法是通用验证法,因此参考已有文献进行,资本市场验证法是本文新提出的验证方法。

¹ 我们不设置任何阈值,直接对技能的人工智能相关度平均汇总至岗位和公司层面,重新测算了企业人工智能相关度。结果显示,本文全部结论均保持稳健。因篇幅所限无法具体呈现,留存备案。

(一) 基于机构评级的验证

参考姚加权等(2024),选用工业和信息化部下属的赛迪研究院的评级作为权威基准。根据赛迪研究院公布的《中国人工智能发展研究报告(2024)》中的“人工智能企业综合实力 TOP 100”榜单,显示上榜企业的人工智能投入水平显著高于未上榜企业。具体而言,103 家上榜企业(含并列)测算出的人工智能投入得分(AIRatio)均值为 0.0617,明显高于未上榜企业的 0.0097,且差值在 1% 的水平上显著¹。这一结果支持了本测度在衡量企业人工智能投入强度方面的可靠性。

(二) 基于专利申请的验证

借鉴李青原和肖泽华(2020)对于绿色专利的识别思路,以国家知识产权局颁布的《关键数字技术专利分类体系》中“人工智能技术”章节的专利分类标准作为索引,通过 IPC 分类号匹配的方式,对专利“是否使用了人工智能技术”进行识别²,并以此定义一个专利申请是否属于人工智能专利。本文通过回归分析,检验了人工智能投入(AIRatio)与企业人工智能专利申请量(lnAI)之间的关系,结果显示,AIRatio 对 lnAI 的系数在 1% 水平上显著为正³。综合来看,企业的人工智能投入水平越高,其人工智能创新水平也相应增加,体现人工智能投入测度的可靠性。

(三) 基于资本市场表现的验证

我们以生成式人工智能工具 ChatGPT 的发布作为人工智能技术进步的标志性事件,通过分析事件窗口期内不同人工智能投入水平企业股价表现的差异,验证本测度结果是否与企业实际人工智能投入情况相符。选择 ChatGPT 发布作为技术进步冲击的依据有以下两点:第一,ChatGPT 具有颠覆性影响,显著提升了市场对人工智能发展前景的预期。在人工智能领域处于领先地位的企业能够率先受益于这一重大技术突破,从而建立新的竞争优势并提升企业价值。因此,一家公司在人工智能上的既有投入水平越高,其股价因 ChatGPT 发布而获得的正向效应理应越显著。第二,ChatGPT 发布对中国资本市场的外生性较强。其开发者 OpenAI 是一家美国公司,目前未见其与中国企业存在技术合作的证据。此外,通过查阅“ChatGPT”的百度搜索指数和百度资讯指数可知,在发布前,该词条的搜索流量和资讯报道均为零。这一特征为研究提供了一个较为干净的因果识别环境,使得 ChatGPT 发布窗口期内的股价变化可合理归因于该事件的影响。

考虑到 2022 年 11 月 30 日 ChatGPT 发布后,其影响力传导到中国资本市场需要一定时间,我们将 ChatGPT 在中国股票市场的事件窗口期设定为 2022 年 12 月 30 日至 2023 年 4 月 1 日,为期三个月。为了保证结果的稳健性,以 ChatGPT 的真实发布日期 2022 年 11 月 30 日为起始点,2022 年 11 月 30 日至 2023 年 3 月 1 日为窗口期进行了检验,结果保持稳健。

1 限于篇幅,详细对比结果见附录附表 3。

2 国家知识产权局颁布的《关键数字技术专利分类体系》详见 www.cnipa.gov.cn/attach/0/d32119ae1faa4fb9e308824862f87dd.pdf。

3 限于篇幅,详细回归结果见附录附表 4。




图 1 2022—2024 年人工智能投入高一低组合的股价收益走势图

根据本方法测算的 2022 年人工智能技术投入水平,我们将所有上市公司按人工智能投入得分从高至低分为 5 组。图 1 以 2022 年 12 月 30 日为业绩基准,展示了 2022—2023 年间高人工智能投入(Group 5,前 20%)和低人工智能投入(Group 1,后 20%)相关股票,以及由此构建的多空组合的累计收益率变化情况。从图 1 中可以很明显地看出,在 ChatGPT 发布之前,两类股票的收益率高度重合,可见并不存在事前趋势;而在 ChatGPT 发布之后,两类股票的收益率迅速拉开差距。由此可见,在投资者眼中,本文测度出来得分高低不同的公司,除了在人工智能投入这一方面外,其他方面不存在明显差异,证明了本测度的准确性。

表 1 不同时间段的人工智能投入多空组合的股价收益(日度)

Panel A:事后窗口期的分组收益率						
	Group 1	Group 2	Group 3	Group 4	Group 5	AMH
原始收益(%)	0.1440	0.1565	0.2014 *	0.2784 **	0.3889 ***	0.2449 ***
CAPM 调整收益(%)	-0.4459 ***	-0.4348 ***	-0.3886 ***	-0.3047 ***	-0.1879	0.2580 ***
五因子调整收益(%)	-0.4823 ***	-0.4555 ***	-0.4150 ***	-0.3445 ***	-0.2306 ***	0.2517 ***
Panel B:事前窗口期的分组收益率						
	Group 1	Group 2	Group 3	Group 4	Group 5	AMH
原始收益(%)	0.1195	0.1513	0.1192	0.1788	0.1479	0.0283
CAPM 调整收益(%)	-0.3944 ***	-0.3597 ***	-0.3964 ***	-0.3345 ***	-0.3667 ***	0.0277
五因子调整收益(%)	-0.4434 ***	-0.3824 ***	-0.4338 ***	-0.3841 ***	-0.4295 ***	0.0139

注:***p<0.01,**p<0.05,*p<0.1 分别代表在 1%、5%、10% 的水平上显著,下表同。考虑到资产收益之间可能存在异方差和时间序列相关,因此采用 Newey - West 方法估计稳健标准误(HAC),滞后期数为 5 期。调整收益指的是去除因子模型期望收益和无风险利率之后的收益率。日度化无风险利率(%)数据由 CSMAR 根据年度定期整存整取利率调整计算得出。

我们进一步通过具体数据,在表1更严谨地呈现了图1的结果。事后窗口期设定为2022年12月30日至2023年4月1日,事前窗口期设定为2022年10月1日至2022年12月30日。表1列示了两个阶段内各组公司的日均收益率、经CAPM市场风险溢价调整后的日均阿尔法收益率,以及经Fama – French五因子模型调整后的日均阿尔法收益率。因子载荷(贝塔)的估计基于窗口期前6个月的数据。AMH(Artificial Minus Human)代表“做多Group 5、做空Group 1”的零投资对冲组合,其收益率反映了人工智能投入测度所揭示的无风险套利收益。在事后窗口期内,Group 5企业的原始收益率和阿尔法收益率均显著高于Group 1,且各组收益率呈现逐级递增趋势。而在事前窗口期内,Group 5与Group 1在三种收益率上的差异均不显著,各组间的收益率也无明显趋势性变化。这一结果再次证明,本文所提出的人工智能投入测度,能够被资本市场表现所印证。

以上分析是基于对人工智能投入水平的离散分组。为进一步展示人工智能投入与收益率的关系,进一步用事件窗口期内的累计超额收益CAR对人工智能投入做横截面回归分析,以考察人工智能投入的边际变化对CAR的影响。我们分别进行了单变量回归、加入行业固定效应、在控制行业固定效应的基础上纳入公司规模(以总资产衡量),以及进一步控制三个公司信息环境变量后进行回归,即是否由四大会计师事务所审计(Big4Y)、分析师关注度(AnaAttention)和公司透明度(CompanyOpacity)。

参考Hirshleifer and Sheng(2022),在事件 $[\tau + h, \tau + H]$ 区间内,股票 k 的CAR的计算方式为:

$$CAR[h, H] = (\prod_{j=\tau+h}^{\tau+H} (1 + R_{j,k}) - 1) - \beta_{j,k} (\prod_{j=\tau+h}^{\tau+H} (1 + R_{j,m}) - 1)$$

我们选择 $h = 1, H = 90$,相当于3个月的窗口期。代表股票 k 在窗口期内第 j 天的日度收益率,代表在窗口期内第 j 天的全市场收益率,是股票 k 在窗口期内第 j 天的贝塔值。仍然采用60日滚动回归的方式来估计贝塔值,结果显示,按照本文方法测算出来人工智能投入指标,和股票在事件窗口期内的CAR显著正相关。因篇幅所限,结果参见附录附表5。

以上评级验证法、专利验证法和资本市场验证法的结果一致表明,本文提出的测度方式,能够准确地捕捉到不同企业之间的人工智能投入强度差异。

四、人工智能投入的时序与行业变化趋势

下面基于CnOpendata整理的智联招聘平台上713万条上市公司招聘数据,对2015年至2022年间中国上市公司的人工智能情况进行测度,并分析其时间序列和行业截面上的变化趋势。我们选择2015年作为考察的起始点,因为2015年被普遍认为是人工智能技术出现显著进步、开始被大规模应用在各个行业的起始年份(LeCun et al., 2015; Hunt et al., 2022)。

(一)时间序列变化趋势

结果显示,所有上市公司的人工智能投入均值从2015年的0.0023持续增长,在2020

年达到了高峰(0.0157),随后出现了轻微的回落,至 2022 年仍超过 0.01(0.0130)。特别地,2016—2018 年,人工智能投入增加了近四倍,其中 2016—2017 年增长最快,增幅约为 137%。图 2 展示了时间变化趋势。




图 2 中国上市公司平均人工智能投入的时间序列趋势

(二)行业变化趋势

我们同样考察了 2015—2022 年期间不同行业的人工智能投入情况。行业分类基于国家统计局标准的行业分类。整体而言,“信息传输、软件和信息技术服务业”以及“金融业”表现出最高的人工智能投入强度。具体而言,信息技术服务业的 AI 关联性超过 0.03,金融业则超过 0.025,显示出中国金融业对于人工智能技术有着强烈的投入意愿。相较之下,“农、林、牧、渔业”、“采矿业”和“住宿和餐饮业”的人工智能投入程度较低,表明这些行业的人工智能技术应用尚处于起步阶段。因篇幅所限,结果参见附录附图 2。

从分行业年度变化情况来看,除了“公共管理”、“水利、环境和公共设施管理业”和“住宿和餐饮业”出现微弱下降外,其他所有行业的投入强度 2019—2022 年相较于 2015—2018 年均出现显著增长,尤其是“信息传输、软件和信息技术服务业”、“金融业”、“采矿业”和“交通运输、仓储和邮政业”,这表明人工智能技术正在逐步渗透到更多行业中。因篇幅所限,结果参见附录附图 3。

五、投入与披露视角的对比分析

通过对上市公司年报中披露的文本信息进行挖掘并基于此测度企业人工智能水平,是否与基于企业人力资本投入的测度相符? 如果两者不一致,那么基于披露信息的测度是否具有过度宣传的问题,还是与基于投入的测度相比,捕捉了企业人工智能发展的不同侧面? 我们使用本文测算结果作为一个可靠的外部基准,通过对比揭示人工智能披露所

真实承载的信息内容。

(一)相关性分析

借鉴姚加权等(2024),我们使用机器学习生成的 73 个人工智能关键词构建人工智能词典,并计算企业年报中管理层讨论与分析(MD&A)部分人工智能词汇占总词汇的比例(取对数)作为企业人工智能披露强度的代理变量 $\ln wordsMDA$ 。

为全面验证中国企业在人工智能领域的“言行一致”程度,我们基于实证数据开展了以下分析。考虑到部分公司可能未在智联招聘平台发布招聘信息,将此类公司纳入比较可能导致对上市公司投入水平的误判,我们筛选出当年在智联招聘上至少发布 20 个招聘岗位的公司,以此排除平台选择效应对结果的潜在干扰。随后通过回归分析,检验了人工智能投入变量 $AIRatio$ 与披露强度变量 $\ln wordsMDA$ 之间的相关关系。表 2 展示的回归分析结果显示,总体上我国企业的人工智能投入强度和披露强度呈现显著正相关关系。

表 2 人工智能投入与人工智能披露的回归分析

变量	(1) $\ln wordsMDA$	(2) $\ln wordsMDA$	(3) $\ln wordsMDA$
$AIRatio$	5. 8157 *** (4. 1657)	3. 5288 *** (6. 0361)	3. 0918 *** (5. 6465)
常数项	0. 6635 *** (5. 1465)	0. 6801 *** (159. 3854)	0. 6833 *** (170. 9696)
行业固定效应	No	Yes	Yes
时间固定效应	No	No	Yes
样本量	19761	19761	19761
$Adj. R^2$	0. 0300	0. 2851	0. 3123

注:小括号内为聚类到行业层面的稳健标准误对应的 t 值,***、**、* 分别代表在 1%、5% 和 10% 的显著性水平上显著,下表同。

进一步地,我们将投入强度和披露强度转化为 0 – 1 二元变量,通过两两配对将样本划分为“只说不做”“只做不说”“不说不做”和“言行一致”四类。结果显示,首先,“只说不做”(即仅有披露而无实际投入)的样本数量远超“只做不说”(即有投入但无披露)的样本数量。在所有至少进行过一次人工智能披露的样本(共 8645 个)中,“只说不做”的占比高达 64%。其次,在总样本中,有 48% 的企业既未投入也未披露。上述分析表明,我国上市公司的人工智能披露与投入在整体上存在一定一致性,但在大量个体样本中仍表现出显著差异。具体配对分类结果参见附录附表 6。

表 3 人工智能披露和企业全要素生产率

变量	全样本		其余样本		“只说不做”样本	
	(1)	(2)	(3)	(4)	(5)	(6)
	<i>TFP_GMM</i>	<i>TFP_GMM</i>	<i>TFP_GMM</i>	<i>TFP_GMM</i>	<i>TFP_GMM</i>	<i>TFP_GMM</i>
<i>lnwordsMDA</i>	0.0347 *** (3.9060)	0.0114 ** (2.0335)	0.0575 *** (3.3402)	0.0269 ** (2.5941)	0.0012 (0.0968)	-0.0076 (-0.7128)
常数项	5.7230 *** (972.3342)	-3.5450 *** (-5.3073)	5.7409 *** (836.3403)	-3.1439 *** (-4.4948)	5.7048 *** (305.4968)	-4.3767 *** (-2.7962)
控制变量	No	Yes	No	Yes	No	Yes
企业固定效应	No	Yes	No	Yes	No	Yes
时间固定效应	Yes	Yes	Yes	Yes	Yes	Yes
样本量	19196	18616	13568	13123	4680	4569
<i>Adj. R</i> ²	0.8744	0.9097	0.8809	0.9148	0.9165	0.9391

能否认为这些“只说不做”的样本并没有真正使用人工智能？我们通过比较不同类型的企业样本,其人工智能披露强度和全要素生产率之间的关系来进行考察。这一方法的逻辑在于,人工智能技术是促进全要素生产率提升的有力工具。因此,如果一个企业的人工智能披露确实反映了其人工智能技术使用情况,那么我们应该观察到人工智能披露和全要素生产率之间存在正相关关系;反之则说明人工智能披露和真实使用之间存在偏差。我们使用 GMM(广义矩估计)方法计算了企业的全要素生产率(*TFP_GMM*)。表 3 报告了分样本回归结果。首先,在全样本以及剔除“只说不做”企业后的其余样本中,人工智能披露水平与全要素生产率显著正相关(第(1)、(2)列)。这一结果与姚加权等(2024)的发现相互印证,表明在一般情况下,人工智能披露水平高的企业往往具有更高的生产率表现。相比之下,在“只说不做”子样本中,人工智能披露对全要素生产率并未呈现显著的促进作用,体现为系数均不显著,且第(6)列为负,反映出其披露难以转化为真实的效率提升。进一步地,当排除“只说不做”样本后,人工智能披露的系数进一步正向扩大(第(3)、(4)列),说明“只说不做”样本确实会干扰总体样本中对于披露水平和全要素生产率之间关系的识别。上述结果在控制了一系列企业特征变量,包括 *Age*(企业成立时长)、*Size*(以总资产衡量的企业规模)、*Board*(企业董事会人数)、*R&DRatio*(企业研发投入占总收入的比例)、*Leve*(资产负债率)、*TobinQ*(企业托宾 Q 值)、*Growth*(企业销售收入增长率)、*Top1*(股权集中度),以及年份和企业个体固定效应之后仍然稳健成立。由此可见,“只说不做”样本,其人工智能披露和全要素生产率之间的关系异于其他样本,有较大概率是由于并未实际使用人工智能技术¹。

1 限于篇幅,未报告控制变量的描述性统计结果,留存备索。

企业为何要“只说不做”? 一个直观的解释是,这些企业对并未使用的人工智能进行了过度宣传。然而,鉴于“只说不做”样本在全样本中占据较大比例,若完全归因于粉饰,则意味着企业年报存在大规模虚假披露,这一结论将引申出诸多值得商榷的问题。我们认为,将披露和投入的不一致直接视为粉饰过于武断。下文试图寻找并论证其他替代假设,以解释为何企业的披露和投入之间存在差异。

(二)披露前瞻性分析

第一个替代解释是,披露可能具有一定的前瞻性。前瞻性是指对于公司未来行为或者盈利的规划和预计,是公司年报,特别是管理层分析与讨论部分的重要内容(潘越等, 2021; Cadman et al., 2023)。如果企业对于人工智能的披露是前瞻性披露,那就意味着和当前的人工智能投入之间存在时间错配。

表 4 企业人工智能披露与下期人工智能投入——OLS/Probit 回归与边际效应估计

变量	OLS Regression	Probit Regression	
	<i>Do_F1</i>	<i>Do_F1</i>	<i>Do_F1</i> (<i>dy/dx</i>)
<i>Say</i>	0. 0743 *** (13. 1725)	0. 3614 *** (11. 1916)	0. 0919 *** (11. 9843)
<i>Do</i>	0. 4912 *** (31. 1892)	1. 4386 *** (36. 5105)	0. 3659 *** (41. 6611)
常数项	0. 1190 *** (27. 9539)	-1. 2190 *** (-34. 6313)	
行业固定效应	Yes		
时间固定效应	Yes		
样本量	15177	15177	15177
<i>Adj. R</i> ²	0. 2973		

我们通过考察当前披露和下一期投入之间的关系,来区分粉饰和前瞻性。其逻辑在于,如果人工智能披露完全是没有依据的粉饰行为,那么当前披露并不会预示着下一期会进行投入;而如果披露具有前瞻性,则应该发现当前披露对下一期投入具有指示意义。表 4 展示了相关结果。其中 0-1 变量 *Say* 代表当期“是否披露”,0-1 变量 *Do* 代表当期是否投入,0-1 变量 *Do_F1* 代表下一期是否投入。OLS 回归和 Probit 回归结果一致表明,当企业在 *t* 期的 AI 披露(*Say*)行为和 *t* + 1 的 AI 投入行为之间呈现显著正相关关系。第(3)列展示了基于 Probit 回归结果计算的边际效应:与当期不披露的企业相比,当期披露的企业,其在 *t* + 1 期进行 AI 投入(*Do_F1* = 1)的概率平均提高 9.2 个百分点。

进一步将考察范围聚焦在“只说不做”样本,研究这一粉饰可疑度最高的行为特征是否仍可能被披露前瞻性所解释。为控制其他变量的干扰,我们将样本限定为“不说不做”和“只说不做”两类,这一设定等价于在给定 *Do* = 0 的条件下,再次考察当期的披露是否

预示着下一期的投入。回归结果显示¹,与完全不涉及 AI 的“不说不做”样本相比,“只说不做”在下一期开始 AI 招聘的概率平均高出 8.3%,且该数值在 1% 的水平上显著。

上述分析表明,“言行不一”的现象并不一定意味着企业存在故意误导的动机,也可能是披露行为领先于实际行动的准备期阶段表现。

(三)披露倾向性分析

第二个替代假设是,人工智能披露所反映的可能并非企业自身投入,而是企业所处业务与人工智能的关联程度。为检验这一点,我们基于企业主营业务表述与“人工智能”之间的文本相似度构造业务关联度指标,并借鉴 Duarte et al. (2020) 的 mechanical heuristics test,比较该指标对人工智能披露强度和投入强度的解释力差异。具体做法是:按年度截面均值将企业划分为高关联度和低关联度两组,再分别回归披露强度和投入强度,并比较各自的拟合优度。结果表明,业务关联度的机械变动平均可解释 8.2% 的披露变化,但仅能解释 2.1% 的投入变化,且这一差异在各年份均一致存在。这说明,人工智能披露相比人工智能投入更强地受到信息内容差异的影响,这也是二者不一致的重要原因之一。

(四)投资者信息解读分析

最后,我们考察投资者如何解读披露与投入信息,尤其关注其是否会对二者之间的不匹配作出反应,并结合投入数据加以核实。这有助于理解投资者如何认识企业技术变革,进而分析人工智能使用的资本市场影响,并为完善相关披露制度提供参考。我们仍利用 ChatGPT 发布带来的外生事件窗口,按照第三部分相同方法计算各股票的累计超额收益(CAR)。进一步地,按中位数将样本划分为高/低披露与高/低投入,并两两匹配形成四组,通过比较组间 CAR 溢价来刻画投资者的信息解读行为:若某一标签高低组之间不存在显著溢价,则说明投资者并不重视该信息。为比较即时反应与中长期反应,将三个月窗口进一步划分为事件后第一个交易周(0 至第 4 个交易日)和此后至三个月(第 5 个至第 61 个交易日)两个阶段,并参考 Loh(2010)对各组 CAR 取简单平均。表 5 据此报告各组 CAR 及其溢价结果,其中披露溢价反映投资者对披露信息的重视程度,投入溢价则反映其对投入信息的重视程度。

从披露溢价看,无论股票属于高投入还是低投入组,短窗口还是长窗口,高披露相对于低披露的 CAR 优势始终显著。这说明,部分投资者会直接依据披露信息进行判断,“低投入高披露”所隐含的潜在偏差并未阻止市场对高披露股票的偏好。

上述结论并不意味着投入信息不重要。首先,在两个窗口期内,披露与投入相匹配的“高投入高披露”股票始终表现最好,其相对于“低投入高披露”股票的溢价均显著存在。其次,虽然披露溢价在不同投入组中都成立,但高投入组的披露溢价显著高于低投入组,表明投资者在关注披露信息的同时,也会进一步结合投入信息进行判断,只是二者存在明显优先级:先看披露,再看投入;只有在披露较高时,投入较高才会带来额外认可。也正因为如此,“低披露高投入”企业并未获得显著的“谦虚溢价”。

1 因篇幅所限,详细回归结果留存备索。

进一步比较短窗口与长窗口可以发现,投资者对投入信息的消化明显慢于对披露信息的消化:高披露公司的投入溢价在事件后首周即显现,而低披露公司的投入溢价在短期内并不显著,需在更长窗口内才逐步体现。这表明,当缺乏披露信息指引时,投资者需要更长时间识别企业真实投入。总体而言,结果凸显了披露信息在投资者评估企业人工智能水平中的关键作用,也说明规范文本披露、减少潜在粉饰行为具有重要意义。

表 5 不同时间段人工智能投入—披露组合的平均 CAR

Panel A: 即时反应窗口期			
	高投入	低投入	高一低投入溢价
高披露	-0.0084 ***	-0.0158 ***	0.0074 ***
低披露	-0.0256 ***	-0.0247 ***	-0.0009
高一低披露溢价	0.0172 ***	0.0089 ***	0.0083 **
Panel B: 中长期反应窗口期			
高披露	-0.1433 ***	-0.2073 ***	0.0641 ***
低披露	-0.2497 ***	-0.2707 ***	0.0210 ***
高一低披露溢价	0.1064 ***	0.0633 ***	0.0431 ***

六、结论与政策建议

本文构建了基于招聘大数据的测度方法,尝试从人力资本视角量化我国企业的人工智能投入强度。测度方法经过了评级验证法、专利验证法和资本市场验证法的检验,具有可靠性和广泛适用性,能够为关于企业人工智能投入相关经济后果的研究提供工具支持。使用本测度考察我国上市公司 2015—2022 年之间的人工智能投入情况,有以下发现:一是我国企业人工智能投入整体上呈逐年上升趋势;二是企业人工智能投入具有显著的分化特征,行业之间差异明显,不同分位数水平企业间的差距也持续扩大;三是相当一部分企业在人工智能领域的文本披露与其实际投入水平存在明显差异,这一差异既可能来自企业的夸大宣传,也可能是由于披露内容涵盖了投入以外的其他相关信息。因此,在基于文本披露进行信息提取与变量构建时,应更加细致地甄别与区分不同类型信息。若因担忧粉饰行为而完全舍弃披露数据,将错失重要且具有价值的信息来源,但若不加甄别地直接使用,又可能导致研究结论的解读出现偏差。

基于上述结论,本文提出以下相关政策建议。

第一,推动传统产业人工智能应用转型。当前我国企业人工智能投入呈现显著的行业分化特征,传统产业智能化投入整体相对不足。应坚持“应用导向、场景牵引”,通过财政补贴、税收优惠及专项资金支持等方式降低企业智能化改造成本;同时围绕质量检测、设备运维、供应链管理、客户服务等典型应用场景打造示范项目,以提升智能化升级的推

广与扩散效率。

第二,完善人工智能人才培养与流动机制,缓解企业投入中的人力资本约束。本文研究表明,人工智能投入高度依赖相关人才配置能力。应推动高校、职业教育与企业协同育人,完善课程体系与技能认证,同时,优化跨地区、跨企业流动和继续教育培训制度,缓解企业在人工智能投入初期面临的人才瓶颈。

第三,加强对人工智能扩散及企业分化的监测,防范“人工智能鸿沟”。本文研究发现,企业间人工智能投入差异显著,且与生产率提升密切相关,说明技术扩散不均可能加剧企业分化。应建立常态化监测机制,动态跟踪人工智能投入、生产率和市场结构变化,并对潜在的市场集中和竞争失衡风险及时采取针对性措施。

第四,完善上市公司人工智能披露规范并强化真实性监管。本文研究表明,部分企业存在人工智能披露与实际投入脱节的现象,可能误导投资者和监管部门。应细化人工智能披露标准,推动定性与定量披露相结合,关注招聘、研发和专利等可验证信息,强化一致性核查,减少“只说不做”带来的资源错配。

参 考 文 献

[1]方明月、林佳妮和聂辉华,2022,《数字化转型是否促进了企业内共同富裕?——来自中国 A 股上市公司的证据》,《数量经济技术经济研究》第 11 期,第 50 ~ 70 页。

[2]方颖、王翔宇、叶梦芊和赵西亮,2025,《中国上市企业的“人工智能+”创新:理论分析与实证证据》,工作论文。

[3]何晓斌和石一琦,2019,《人工智能的发展和我国人工智能文科人才的培养》,《清华大学教育研究》第 4 期,第 32 ~ 38 页。

[4]金星晔、左从江、方明月、李涛和聂辉华,2024,《企业数字化转型的测度难题:基于大语言模型的新方法与新发现》,《经济研究》第 3 期,第 34 ~ 53 页。

[5]李青原和肖泽华,2020,《异质性环境规制工具与企业绿色创新激励——来自上市企业绿色专利的证据》,《经济研究》第 9 期,第 192 ~ 208 页。

[6]李哲、李心武、焦焰和张文婷,2024,《“多言寡行”的数字化转型披露与分析师预测行为》,《会计研究》第 9 期,第 61 ~ 75 页。

[7]刘飞和田高良,2019,《信息技术是否替代了就业——基于中国上市公司的证据》,《财经科学》第 7 期,第 95 ~ 107 页。

[8]马慧和陈胜蓝,2022,《企业数字化转型、坏消息隐藏与股价崩盘风险》,《会计研究》第 10 期,第 31 ~ 44 页。

[9]潘越、林淑萍、张鹏东和戴亦一,2021,《语言将来时态标记特征与公司股利政策——基于投资者语言认知效应的跨国研究》,《经济研究》第 7 期,第 127 ~ 143 页。

[10]祁怀锦、曹修琴和刘艳霞,2020,《数字经济对公司治理的影响——基于信息不对称和管理者非理性行为视角》,《改革》第 4 期,第 50 ~ 64 页。

[11]邵红霞和方军雄,2006,《我国上市公司无形资产价值相关性研究——基于无形资产明细分类信息的再检验》,《会计研究》第 12 期,第 25 ~ 32 页。

[12]陶锋、王欣然、徐扬等,2023,《数字化转型、产业链供应链韧性与企业生产率》,《中国工业经济》第 5 期,第 118 ~ 136 页。

[13]吴非、胡慧芷、林慧妍和任晓怡,2021,《企业数字化转型与资本市场表现——来自股票流动性的经验证据》,《管理世界》第 7 期,第 130 ~ 144 页。

- [14]肖土盛、孙瑞琦、袁淳等,2022,《企业数字化转型、人力资本结构调整与劳动收入份额》,《管理世界》第12期,第220~237页。
- [15]许宪春、雷泽坤和胡亚茹,2025,《中国数据资本形成总额与数据资本存量测算》,《经济研究》第3期,第54~68页。
- [16]姚加权、张银澎、郭李鹏和冯绪,2024,《人工智能如何提升企业生产效率?——基于劳动力技能结构调整的视角》,《管理世界》第2期,第101~116、117~122、133页。
- [17]张俊芳、郭戎和郭永济,2018,《中国无形资产测度及其对科技进步贡献率影响的研究》,《科学学与科学技术管理》第1期,第46~54页。
- [18]赵宸宇、王文春和李雪松,2021,《数字化转型如何影响企业全要素生产率》,《财贸经济》第7期,第114~129页。
- [19]Acemoglu, D. and D. Autor, 2011, "Skills, Tasks and Technologies: Implications for Employment and Earnings", *Handbook of Labor Economics*, Vol. 4, pp. 1043~1171. Amsterdam: Elsevier.
- [20]Autor, D., C. Chin, A. Salomons and B. Seegmiller, 2024, "New Frontiers: The Origins and Content of New Work, 1940 - 2018", *The Quarterly Journal of Economics*, 139(3), pp. 1399~1465.
- [21]Babina, T., A. Fedyk, A. He and J. Hodson, 2024, "Artificial Intelligence, Firm Growth, and Product Innovation", *Journal of Financial Economics*, 151, 103745.
- [22]Brynjolfsson, E., D. Rock and C. Syverson, 2021, "The Productivity J-Curve: How Intangibles Complement General Purpose Technologies", *American Economic Journal: Macroeconomics*, 13(1), pp. 333~372.
- [23]Cadman, B., M. S. Heinle and D. Macciocchi, 2023, "Insider Horizon and Disclosure Policies", *The Accounting Review*, 98(4), pp. 55~88.
- [24]Chu, J., Y. He, K. W. Hui and R. Lehavy, 2025, "New Product Announcements, Innovation Disclosure, and Future Firm Performance", *Review of Accounting Studies*, 30(1), pp. 352~383.
- [25]Darendeli, A., K. K. Law and M. Shen, 2022, "Green New Hiring", *Review of Accounting Studies*, 27(3), pp. 986~1037.
- [26]Duarte, J., E. Hu and L. Young, 2020, "A Comparison of Some Structural Models of Private Information Arrival", *Journal of Financial Economics*, 135(3), pp. 795~815.
- [27]Hirshleifer, D. and J. Sheng, 2022, "Macro News and Micro News: Complements or Substitutes?", *Journal of Financial Economics*, 145(3), pp. 1006~1024.
- [28]Hunt, W., S. Sarkar and C. Warhurst, 2022, "Measuring the Impact of AI on Jobs at the Organization Level: Lessons from a Survey of UK Business Leaders", *Research Policy*, 51(2), 104425.
- [29]Jiang, W., J. Park, R. J. Xiao and S. Zhang, 2025, "AI and the Extended Workday: Productivity, Contracting Efficiency, and Distribution of Rents", *NBER Working Paper*, No. 33536.
- [30]LeCun, Y., Y. Bengio and G. Hinton, 2015, "Deep Learning", *Nature*, 521(7553), pp. 436~444.
- [31]Loh, R. K., 2010, "Investor Inattention and the Underreaction to Stock Recommendations", *Financial Management*, 39(3), pp. 1223~1252.
- [32]Müller, O., M. Fay and J. Vom Brocke, 2018, "The Effect of Big Data and Analytics on Firm Performance: An Econometric Analysis Considering Industry Characteristics", *Journal of Management Information Systems*, 35(2), pp. 488~509.
- [33]Pástor, . and P. Veronesi, 2006, "Was There a Nasdaq Bubble in the Late 1990s?", *Journal of Financial Economics*, 81(1), pp. 61~100.
- [34]Rock, D., 2022, "Engineering Value: The Returns to Technological Talent and Investments in Artificial Intelligence", *Brookings Institution Center on Regulation and Markets Working Paper*.
- [35]Sharma, S. S. and P. K. Narayan, 2022, "Technology Shocks and Stock Returns: A Long-Term Perspective",

AI Investment of Chinese Firms:
Findings Based on Large – Scale Job Posting Data

FANG Ying WANG Xiangyu YE Mengqian ZHAO Xiliang

(Wang Yanan Institute for Studies in Economics/Interdisciplinary Laboratory of Big Data Finance/
Paula and Gregory Chow Institute for Studies in Economics, Xiamen University;
Fujian Institute of Scientific and Technical Information)

Summary: Measuring firm – level artificial intelligence (AI) investment is central to understanding technology adoption, productivity upgrading, and market valuation, yet direct accounting measures are limited because most AI inputs are intangible and rarely separated in financial statements. Existing proxies based on annual – report wording, IT hardware spending, or patent output capture only part of the process and can blur real investment behavior. Building on the view that AI adoption is human – capital intensive, this study develops a recruitment – based measure that tracks whether firms are actually allocating resources to AI capability development. The core idea is that hiring demand for AI – related skills reflects concrete investment decisions at the implementation stage, thereby providing a scalable, behavior – based indicator that complements disclosure – based metrics.

To operationalize this idea, we construct a Chinese labor – skill dictionary with 99,463 skills by integrating Lightcast, O * NET, and ESCO and then localizing the lexicon with a BERT – based named – entity – recognition pipeline trained on Chinese job texts. Using skill co – occurrence with four anchor concepts (AI, machine learning, image recognition, and natural language processing), we compute an AI relevance score for each skill, aggregate scores to the posting level, and classify a posting as AI – related when its average relevance exceeds 0.05. We then define AIRatio at the firm – year level as the share of AI – related postings in total postings. This framework follows a transparent skill – to – position – to – firm aggregation logic and can be extended to other technologies by replacing anchor skills.

The empirical sample combines 7.13 million postings from the Zhaopin platform (organized by CnOpenData and matched to listed firms) with annual – report disclosures from CNINFO, AI patent information identified under China National Intellectual Property Administration (CNIPA) rules, and accounting and market variables from CSMAR, covering the period from 2015 – 2022. We validate AIRatio through three complementary tests. First, benchmark validation shows strong discrimination: firms on the CEIDI Top 100 AI list have a much higher mean AIRatio than other firms (0.0617 versus 0.0097). Second, patent validation shows a significantly positive association between AIRatio and AI patent applications. Third, a capital – market validation based on the release of ChatGPT on November 30, 2022, shows that high – AIRatio portfolios outperform low – AIRatio portfolios in China’s event window (from December 30, 2022 to April 1, 2023), and firm – level cumulative abnormal returns are positively related to AIRatio.

Using AIRatio, we document a substantial increase in AI investment among Chinese listed firms from 0.0023 in 2015 to 0.0157 in 2020, followed by a mild normalization to 0.0130 in 2022. Industry heterogeneity is

substantial, with information services and finance leading, while agriculture, mining, and hospitality lagging behind. We then compare investment – based and disclosure – based AI measures and find only a modest correlation with frequent firm – level mismatch, including many cases of high disclosure but low contemporaneous hiring. Mechanism analysis indicates that mismatch is not purely cosmetic: disclosure contains forward – looking signals that predict next – period hiring, and it also captures technology positioning and business – AI relatedness beyond current input. In asset pricing, a disclosure premium is broad, while an investment premium is strongest when disclosure is already high, indicating a disclosure – first information hierarchy.

The study contributes in three ways. First, it introduces a scalable and behavior – based AI investment metric that is less dependent on voluntary narrative disclosure. Second, it clarifies the different information content of disclosure and investment indicators. Third, it provides evidence on how AI adoption in the real economy is transmitted into equity valuation under a major technology shock. Policy implications are to support AI diffusion in traditional sectors through application – oriented incentives, strengthen AI talent training and mobility, monitor widening inter – firm AI gaps, and improve verifiable AI disclosure standards by linking narrative claims to recruitment, R&D, and patent evidence. Future research can extend the framework to non – listed firms, add new input channels such as cloud and compute spending, and develop stronger causal designs for productivity, labor, and competition effects of AI diffusion.

Keywords: AI Investment, Job Posting Data, Big Data Analysis

JEL Classification:J24, O33, G14

(责任编辑:林梦瑶)(校对:ZL)